Путь статьи: от препринта к журналу

Теоретическая физика высоких энергий (hep-th) · первые версии за 2021 год · данные на 05.11.2026

Для 200 случайных препринтов оценены доля журнальных публикаций, срок выхода и доля Q1.

Главные результаты

Вышли в журналах

90,5%

181 из 200 препринтов

Время до публикации

200,85 дня

Медиана — 140 дней

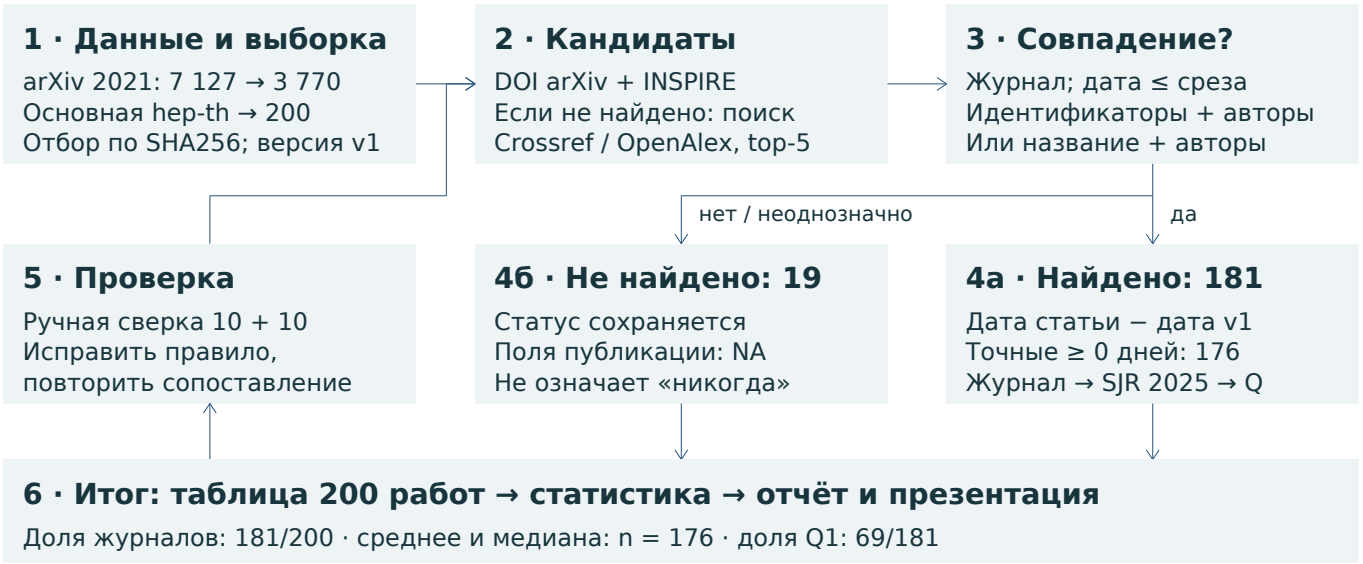
Вышли в журналах Q1

38,1%

69 из 181 публикации

Среднее и медиана — по 176 точным задержкам. Q1 — верхняя четверть журналов SJR; доля Q1 среди всех 200 работ — 34,5%, среди опубликованных — 38,1%.

Как проведено исследование



Отбор. Сортировать arXiv ID основной hep-th за 2021 год по SHA256("hep-th-2021-publication-study-v1:" + ID); взять первые 200. Сохранить дату UTC, авторов и название v1, а также последнее название. Для ненайденных версий взять top-5 Crossref и OpenAlex по каждому из двух названий; DOI раскрыть через Crossref (при отсутствии записи — метаданные INSPIRE).

Правило совпадения. Нормализовать регистр, диакритику (включая ł → l), формулы и пунктуацию. A = общие фамилии / число фамилий меньшего множества. Dice = 2|X ∩ Y|/(|X| + |Y|) для множеств слов. T = 0,65 × Dice + 0,35 × SequenceMatcher строк (`autojunk=False`); взять максимум для v1 и последнего названия. S = 0,75T + 0,25A. Прямая связь: A ≥ 0,5; для DOI arXiv также T ≥ 0,45, для связи INSPIRE по arXiv ID порога T нет. Поиск по названию: T ≥ 0,88, A ≥ 0,5, S ≥ 0,85; отрыв от следующего журнального кандидата с A ≥ 0,5 — не менее 0,05. Приоритет: прямая связь, затем S, затем DOI по алфавиту.

Фильтры и расчёт. Только journal-article; исключить исправления, ретракции, сборники и `refereed=false`. Дата должна быть известна и весь её интервал — не позже 05.11.2026. Приоритет даты: исходный `imprint` при смене DOI; явная online-дата издателя; online Crossref; точный `imprint` INSPIRE; published / `published-print` / `issued` Crossref; неполный `imprint`. created/deposited не использовать. Задержка — дата статьи минус дата v1: 4 неполные даты дают интервалы, 1 отрицательная разность хранится отдельно; в среднем только 176 точных неотрицательных значений. SJR 2025: ISSN/eISSN, иначе точное нормализованное название; лучший квартиль, при отсутствии — NA.

Что показала ручная проверка

Отдельно выбраны и проверены 10 работ, для которых программа нашла статью, и 10, для которых не нашла. Сверены arXiv, INSPIRE и данные издателей. Найдена **1 ошибка из 20**: фамилии Pawelczyk и Pawełczyk программа приняла за разные и пропустила статью. После исправления обработки буквы ł осталось **0 ошибок на тех же 20 работах**. Это повторная проверка после исправления, поэтому она не доказывает отсутствие ошибок во всей выборке.

Контрольные примеры: три найденные статьи и два трудных случая

Смена названия	Препринт 2105.01130 → статья в Classical and Quantum Gravity, 03.03.2022. Название изменилось; связь подтверждена по arXiv ID.
Смена названия и проверка даты	Препринт 2112.15592 → статья в Acta Physica Polonica B, 11.07.2023. Название изменилось; дата проверена в тексте статьи.
Нет DOI в arXiv	Препринт 2104.11336 → статья в SciPost Physics Core, 09.09.2021. DOI найден в INSPIRE по arXiv ID.
Похожие работы	Препринт 2107.01371. У похожих работ другие авторы или arXiv ID. Совпадения отклонены; журнальная версия не найдена.
Два названия, нет статьи	Препринт 2104.14434. Is quantum time the classical time? сменилось на Quantum f(R) gravity and AdS/CFT. Проверены оба названия и INSPIRE; журнальная версия не найдена.

Пять спорных случаев: что решено и почему

1. Изменился DOI — 2111.05295. У статьи появился новый DOI. В новой записи Crossref указано 01.01.2021, а в исходных данных издателя, сохранённых в INSPIRE, — 28.12.2021. Принята дата 28 декабря; новый DOI сохранён. Для расчёта использована исходная дата выхода.

2. Статья вышла до arXiv — 2109.03271. Издатель указывает 02.08.2021, первая версия arXiv подана 07.09.2021. Статья учтена как опубликованная. Разность −36 дней сохранена отдельно, но исключена из среднего времени ожидания после препринта.

3. Найден сборник, а не журнал — 2104.03350. Доклад вышел в PoS ICHEP2020. В Crossref он отмечен как материал конференции. По выбранному правилу в долю журнальных публикаций он не входит; в расчёте со сборниками учитывается.

4. Известен только месяц — 2102.02253. Статья вышла в Nuclear Physics B в ноябре 2021 года. Задержка составляет 271–300 дней. Точное значение не указано: подстановка первого числа месяца создала бы ложную точность.

5. Разное написание фамилии — 2111.07453. У Pawelczyk и Pawełczyk совпадают название статьи, университет и DOI. Это один автор. После исправления сравнения фамилий статья найдена: она вышла 03.06.2022, через 201 день. Именно этот пропуск обнаружен при проверке 20 работ.

Вывод и границы результата

К дате сбора журнальная статья найдена примерно у девяти из десяти препринтов этой выборки. «Не найдено» не значит «никогда не опубликовано»: оставшиеся работы могут выйти позже или отсутствовать в изученных базах. Метод также может пропустить статью, если название сильно изменилось и нет связи по идентификаторам, либо один препринт разделился на несколько статей.

Средняя задержка описывает только найденные публикации с точными датами; это не время рецензирования. Квартиль характеризует журнал и не даёт оценки качества отдельной статьи. Журналы добавляют экспертную проверку, редакционную ответственность и официальную версию для цитирования.

Источники: arXiv, INSPIRE-HEP, Crossref, OpenAlex, издатели; SJR 2025 — сохранённые копии справочника SCImago. Итоговая таблица на 200 работ: preprints.csv в корне проекта. Расчёты можно повторить командой `python3 src/pipeline.py`; результат сохраняется в results/. Численные итоги — results/metrics.json, подробная ручная сверка — results/review_cases.md, причины решений — results/match_audit.json. Правила расчёта и сопоставления приведены выше; воспроизводимый код — в src/pipeline.py.