Путь статьи: от препринта к журналу

Теоретическая физика высоких энергий (hep-th) · первые версии за 2021 год · данные на 05.11.2026

Для 200 случайных препринтов оценены доля журнальных публикаций, срок выхода и доля Q1.

Главные результаты

Вышли в журналах

90,5%

181 из 200 препринтов

Время до публикации

200,85 дня

Медиана — 140 дней

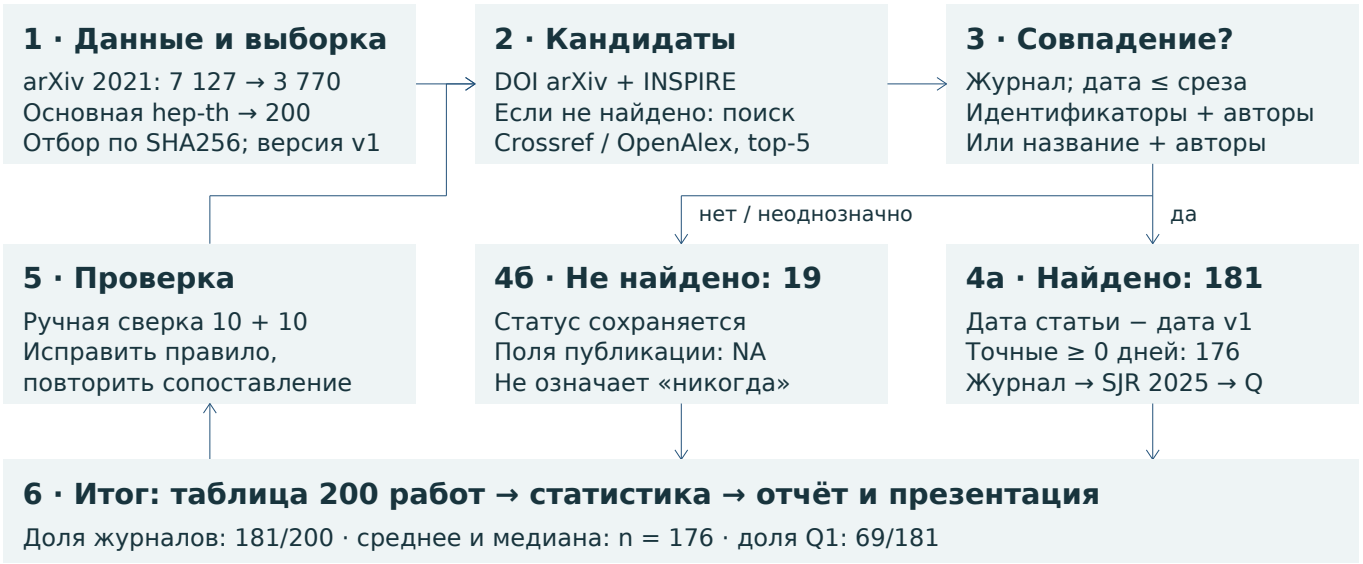
Вышли в журналах Q1

38,1%

69 из 181 публикации

Среднее и медиана — по 176 точным задержкам. Q1 — верхняя четверть журналов SJR; доля Q1 среди всех 200 работ — 34,5%, среди опубликованных — 38,1%.

Как проведено исследование



Отбор. Сортировать arXiv ID основной hep-th за 2021 год по SHA256("hep-th-2021-publication-study-v1:" + ID); взять первые 200. Сохранить дату UTC, авторов и название v1, а также последнее название. Для ненайденных версий взять top-5 Crossref и OpenAlex по каждому из двух названий; DOI раскрыть через Crossref (при отсутствии записи — метаданные INSPIRE).

Правило совпадения. Нормализовать регистр, диакритику (включая ł → l), формулы и пунктуацию. A = общие фамилии / число фамилий меньшего множества. Dice = 2|X ∩ Y|/(|X| + |Y|) для множеств слов. T = 0,65 × Dice + 0,35 × SequenceMatcher строк (`autojunk=False`); взять максимум для v1 и последнего названия. S = 0,75T + 0,25A. Прямая связь: A ≥ 0,5; для DOI arXiv также T ≥ 0,45, для связи INSPIRE по arXiv ID порога T нет. Поиск по названию: T ≥ 0,88, A ≥ 0,5, S ≥ 0,85; отрыв от следующего журнального кандидата с A ≥ 0,5 — не менее 0,05. Приоритет: прямая связь, затем S, затем DOI по алфавиту.

Фильтры и расчёт. Только journal-article; исключить исправления, ретракции, сборники и `refereed=false`. Дата должна быть известна и весь её интервал — не позже 05.11.2026. Приоритет даты: исходный `imprint` при смене DOI; явная online-дата издателя; online Crossref; точный `imprint` INSPIRE; published / `published-print` / `issued` Crossref; неполный `imprint`. created/deposited не использовать. Задержка — дата статьи минус дата v1: 4 неполные даты дают интервалы, 1 отрицательная разность хранится отдельно; в среднем только 176 точных неотрицательных значений. SJR 2025: ISSN/eISSN, иначе точное нормализованное название; лучший квартиль, при отсутствии — NA.

Что показала ручная проверка

Отдельно выбраны и проверены 10 работ, для которых программа нашла статью, и 10, для которых не нашла. Сверены arXiv, INSPIRE и данные издателей. Найдена **1 ошибка из 20**: фамилии Pawelczyk и Pawełczyk программа приняла за разные и пропустила статью. После исправления обработки буквы ł осталось **0 ошибок на тех же 20 работах**. Это повторная проверка после исправления, поэтому она не доказывает отсутствие ошибок во всей выборке.

Контрольные примеры: три найденные статьи и два трудных случая

Смена названия	Препринт 2105.01130 → статья в Classical and Quantum Gravity, 03.03.2022. Название изменилось; связь подтверждена по arXiv ID.
Смена названия и проверка даты	Препринт 2112.15592 → статья в Acta Physica Polonica B, 11.07.2023. Название изменилось; дата проверена в тексте статьи.
Нет DOI в arXiv	Препринт 2104.11336 → статья в SciPost Physics Core, 09.09.2021. DOI найден в INSPIRE по arXiv ID.
Похожие работы	Препринт 2107.01371. У похожих работ другие авторы или arXiv ID. Совпадения отклонены; журнальная версия не найдена.
Два названия, нет статьи	Препринт 2104.14434. Is quantum time the classical time? сменилось на Quantum f(R) gravity and AdS/CFT. Проверены оба названия и INSPIRE; журнальная версия не найдена.

Пять спорных случаев: что решено и почему

1. Изменился DOI — 2111.05295. У статьи появился новый DOI. В новой записи Crossref указано 01.01.2021, а в исходных данных издателя, сохранённых в INSPIRE, — 28.12.2021. Принята дата 28 декабря; новый DOI сохранён. Для расчёта использована исходная дата выхода.

2. Статья вышла до arXiv — 2109.03271. Издатель указывает 02.08.2021, первая версия arXiv подана 07.09.2021. Статья учтена как опубликованная. Разность −36 дней сохранена отдельно, но исключена из среднего времени ожидания после препринта.

3. Найден сборник, а не журнал — 2104.03350. Доклад вышел в PoS ICHEP2020. В Crossref он отмечен как материал конференции. По выбранному правилу в долю журнальных публикаций он не входит; в расчёте со сборниками учитывается.

4. Известен только месяц — 2102.02253. Статья вышла в Nuclear Physics B в ноябре 2021 года. Задержка составляет 271–300 дней. Точное значение не указано: подстановка первого числа месяца создала бы ложную точность.

5. Разное написание фамилии — 2111.07453. У Pawelczyk и Pawełczyk совпадают название статьи, университет и DOI. Это один автор. После исправления сравнения фамилий статья найдена: она вышла 03.06.2022, через 201 день. Именно этот пропуск обнаружен при проверке 20 работ.

Вывод и границы результата

К дате сбора журнальная статья найдена примерно у девяти из десяти препринтов этой выборки. «Не найдено» не значит «никогда не опубликовано»: оставшиеся работы могут выйти позже или отсутствовать в изученных базах. Метод также может пропустить статью, если название сильно изменилось и нет связи по идентификаторам, либо один препринт разделился на несколько статей.

Средняя задержка описывает только найденные публикации с точными датами; это не время рецензирования. Квартиль характеризует журнал и не даёт оценки качества отдельной статьи. Журналы добавляют экспертную проверку, редакционную ответственность и официальную версию для цитирования.

Источники: arXiv, INSPIRE-HEP, Crossref, OpenAlex, издатели; SJR 2025 — сохранённые копии справочника SCImago. Таблица: results/preprints_ru.csv. Пересчёт: make reproduce в корне проекта (Python 3.12, Linux x86_64, make; без сети). Подробная методика и проверки — в полном отчёте results/report.pdf (приложения A–E) и коде.

Приложение A · Как получена выборка

Первые две страницы — краткий отчёт по заданию. Приложение раскрывает правила расчёта и проверки, чтобы исследование можно было понять и повторить без устной защиты. Все результаты относятся к замороженному срезу 05.11.2026.

1. Исследовательский вопрос и единица наблюдения

Какая доля препринтов теоретической физики высоких энергий (hep-th), впервые поданных в 2021 году, имеет журнальную версию к срезу? Сколько календарных дней проходит от подачи первой версии до выхода статьи и какая доля публикаций приходится на Q1? Единица наблюдения — один arXiv ID без суффикса версии. Результат относится к этой категории и когорте.

2. Полная выгрузка, затем отбор

Запрос Atom API: **cat:hep-th AND submittedDate:[202101010000 TO 202112312359]**. Загружаются все страницы по 1 000 записей, последняя — неполная; проверяются общее число и отсутствие дубликатов. Поле published задаёт первую подачу, updated — последнее обновление. Cross-list означает, что hep-th указана дополнительной категорией; такие записи исключаются фильтром `primary_category` == hep-th.

Получены 7 127 записей; 3 357 исключены фильтром основной категории, остаются 3 770. Для каждого ID вычисляется SHA256 от строки **hep-th-2021-publication-study-v1:**, непосредственно дополненной ID (например, 2105.01130), в UTF-8. Хеши сортируются лексикографически; берутся первые 200 без возвращения. Остальные 3 570 не входят в выборку по правилу отбора, а не из-за публикационного исхода. При допущении равномерности хеша это воспроизводимый псевдослучайный отбор.

Дата и исходное название дополнительно сверяются с метаданными v1. Название последней версии сохраняется отдельно для поиска. Сортировка готовой таблицы по ID служит только удобству чтения. Ни DOI, ни журнал, ни квартиль не участвуют в отборе.

3. Что считается публикацией

Основное событие — вышедшая к срезу рецензируемая журнальная статья. Обзоры в журналах включены; сборники, диссертации, главы, новые препринты и исправления вместо исходной статьи исключены. Явный `refereed=false` в INSPIRE запрещает принятие. У 180 принятых статей указан `refereed=true`; у одной Communications Physics флаг отсутствует, поэтому сохранена политика рецензирования журнала.

Это определение выбрано для единообразного сравнения в hep-th. Два подтверждённых сборника показаны отдельно: 181/200 = 90,5% по журнальному определению; (181 + 2)/200 = 91,5% при включении сборников. Разница в 1 процентный пункт характеризует чувствительность к определению.

Приложение Б · Воронка и пути поиска

Отбор выборки и результаты поиска



Схема показывает числа наблюдений, а не ширину пропорциональной воронки. Отбор 200 из 3 770 отделён от поиска публикаций: это разные действия.

Почему одного DOI в arXiv недостаточно

Исходная ветвь	Журнал найден	Не установлен	Всего
DOI указан в arXiv	161	1	162
DOI в arXiv отсутствует	20	18	38
Итого	181	19	200

Точная запись INSPIRE найдена для всех 200 ID. DOI в arXiv или INSPIRE есть у 183 работ, но наличие DOI ещё не означает журнальную публикацию. Все 181 принятые связи в этой выборке подтверждены идентификаторами; резервный поиск по названиям новых положительных результатов не добавил. Он использован для проверки оставшихся случаев.

Из 19 исходов «журнальная версия не установлена» два имеют подтверждённые публикации в сборниках; остальные 17 не имеют принятой журнальной версии или такого подтверждённого сборника. Журнальная версия не найдена в проверенных источниках на 5 ноября 2026 года.

Приложение B · Правила сопоставления

1. Построить список кандидатов

Из метаданных arXiv взять DOI и `journal_ref` как подсказки. В INSPIRE искать точный arXiv ID и проверять его наличие в найденной записи. DOI привести к нижнему регистру, разрешить документированные миграции и получить Crossref-запись. Для ненайденных версий сохранить первые пять результатов Crossref и OpenAlex по последнему названию и отдельно по v1, если название менялось. OpenAlex даёт кандидатов; тип и дата проверяются по регистрационной записи DOI. Кандидаты с одним DOI объединяются.

2. Проверить тип, дату и идентичность

Отклонить тип, отличный от journal-article, явный `refereed=false`, erratum/corrigendum/correction/retraction, отсутствие даты и дату после среза. При неполной дате её верхняя граница должна быть не позже среза. Затем проверить фамилии и название. Сильное переименование допустимо при точной связи arXiv в INSPIRE, но авторы всё равно сверяются.

3. Вычислить признаки

Нормализация удаляет HTML-разметку и оболочки LaTeX, приводит греческие обозначения к латинским именам, & к and, убирает регистр и диакритику; специальные буквы преобразуются явно, например ł→l. Остаются латинские буквы и цифры, слова разделяются одним пробелом. Полная таблица преобразований находится в функции `normalized` в src/pipeline.py.

D = 2|X ∩ Y| / (|X| + |Y|), где X и Y — множества слов названий.
T = 0,65D + 0,35R, где R — ratio Python `difflib.SequenceMatcher` по нормализованным строкам с `autojunk=False`. Берётся максимум T для названия v1 и последнего названия.
A = |U ∩ V| / min(|U|, |V|), где U и V — множества нормализованных фамилий. При пустых данных сходство равно нулю. Для имени с запятой фамилия — часть до запятой, иначе последнее слово; в Crossref предпочтительно поле `family`.

4. Применить пороги и разрешить неоднозначность

Прямая связь требует A ≥ 0,5; если есть только DOI arXiv без точной связи INSPIRE, дополнительно T ≥ 0,45. Резервный поиск требует одновременно T ≥ 0,88, A ≥ 0,5 и S = 0,75T + 0,25A ≥ 0,85. Кандидаты ранжируются сначала по наличию прямой связи, затем по убыванию S, затем по DOI. Для резервного победителя отрыв от другого журнального кандидата с A ≥ 0,5, прошедшего прочие проверки, должен быть ≥ 0,05; иначе результат отклоняется как неоднозначный.

Пороги — открытые эвристики, их оптимальность не доказана. Высокая уверенность означает прямую связь, средняя — принятый резервный поиск, низкая — связь не установлена. В выборке: 181 / 0 / 19 соответственно. Флаг изменения названия сравнивает нормализованные строки без пробелов; 30 изменений включают небольшие редакционные правки. Это не число радикальных переименований.

Приложение Г · Задержки и квартили

Дата события и неполная точность

Начало — календарная UTC-дата подачи v1. Конец — `published-online` в Crossref; при отсутствии — самая ранняя точная дата `imprint` в INSPIRE; затем первое доступное поле Crossref в порядке published, `published-print`, `issued`; в конце — неполный `imprint` INSPIRE. Исходная точность сохраняется. `created` и `deposited` DOI не используются. Конфликты источников разрешаются явно: пример миграции DOI описан на странице 2. Дата принятия статьи не заменяет дату выхода.

Задержка = дата первого выхода − дата v1, в календарных днях. Для четырёх статей известны только месяц и год: это даёт интервал от первого до последнего дня месяца; точный `delay_days` остаётся NA. Одна статья вышла раньше arXiv: −36 дней сохранены в chronology.csv, публикация учитывается, но прямое ожидание не рассчитывается. Итак, из 181 статьи у 176 известны точные даты выхода после arXiv, у четырёх — только месяц; одна вышла до arXiv.



Рис. 1. Число работ в непересекающихся интервалах задержки; знаменатель — 176, единица по горизонтали — дни. Среднее 200,85 дня, медиана 140, диапазон 15–1 281. Длинные ожидания повышают среднее. Это описание завершённых переходов, а не оценка времени рецензирования и не среднее для всех 200 препринтов.

Проверка чувствительности среднего

Среднее — сумма 176 точных задержек, делённая на 176; медиана — среднее двух центральных значений упорядоченного ряда. Если добавить четыре статьи с датами, известными только до месяца и сначала взять все нижние, затем все верхние границы, среднее для 180 прямых исходов лежит в 200,22–200,86 дня. Эти границы отражают точность дат, а не выборочную неопределённость.

Приложение Д · Интерпретация результатов

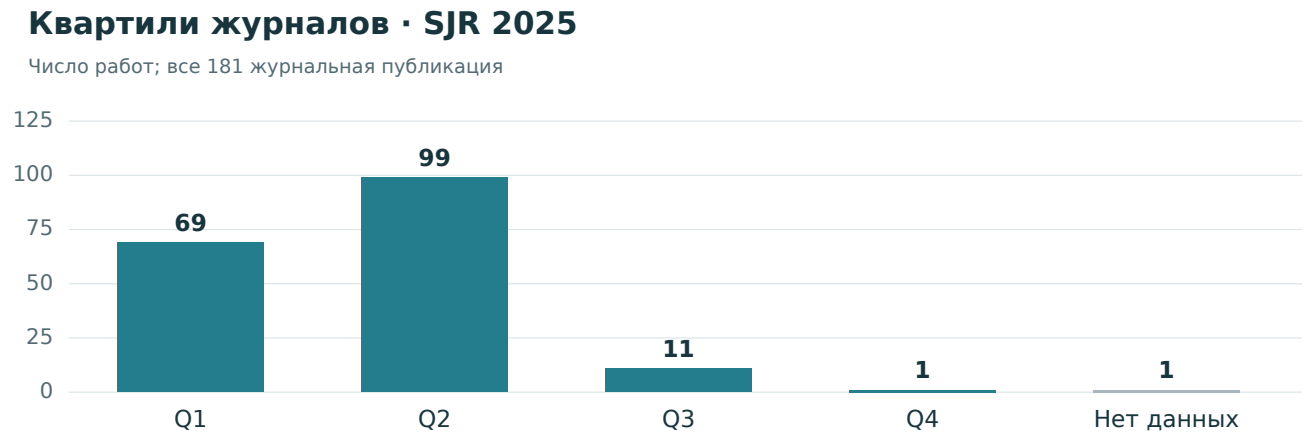


Рис. 2. Число опубликованных работ по лучшему квартилю журнала в SJR 2025. «Нет данных» означает, что квартиль не установлен (NA в таблице данных). Один журнал может принимать много работ: здесь JHEP даёт 76 из 181 публикации и относится к Q2.

Как получен квартиль и выбраны знаменатели

Журнал сопоставляется со справочником SCImago SJR 2025 по ISSN/eISSN; если ISSN отсутствует, используется точное нормализованное название. Берётся SJR Best Quartile, то есть лучший квартиль журнала по категориям. Это единый справочник за 2025 год, а не квартиль на год выхода каждой статьи. Неизвестный квартиль не заменяется Q4. Справочник сохранён из двух побайтно одинаковых зеркал, поскольку прямая выгрузка SCImago вернула 403; URL, коммиты и полные хеши находятся в docs/DATA_SOURCES.md и INPUTS.sha256.

Показатель	Расчёт	Значение
Доля журнальных публикаций	181 / 200	90,5%
Q1 среди опубликованных	69 / 181	38,1%
Q1 среди всей выборки	69 / 200	34,5%
Q1 среди имеющих квартиль	69 / 180	38,33%

Что можно заключить

К срезу журнальная версия найдена примерно у девяти из десяти работ этой выборки. Интервал Уилсона 95% для 181/200 — 85,6–93,8%; он отражает случайный отбор, но не ошибки поиска. Для ненайденных версий полный срок до публикации неизвестен: это правое цензурирование. Наблюдение длится 1 770–2 131 день. Часть работ может выйти позже или уже существовать вне охвата источников. Объединение/разделение текстов и переименование без идентификаторов затрудняют поиск.

Поэтому нельзя переносить результат на все дисциплины или считать 19 работ доказанно неопубликованными. Квартиль характеризует журнал, а не отдельную статью. Журналы организуют рецензирование, редакционную ответственность, исправления и закрепление официальной версии; доступность препринта выполняет другую функцию — быстрое распространение результата.

Приложение E · Как проверить и повторить

Ручная проверка и её границы

Исходные 10 положительных и 10 отрицательных предсказаний отобраны отдельным фиксированным хешем; их состав и исходные ответы сохранены в data/review/baseline_audit.json. Контрольные 3+2 и пять спорных случаев с решениями приведены на странице 2; подробные доказательства всех 29 уникальных случаев — в results/review_cases.md.

Обнаружен один ложный отрицательный ответ из 20: Pawelczyk / Pawełczyk. После исправления нормализации осталось 0/20, а на всём эталоне — 0/29. Эталон применялся при исправлении метода: это регрессионная проверка, а не независимая оценка точности. Отрицательные случаи проверены в доступных источниках; исчерпывающее отсутствие публикации этим не доказано.

Воспроизведение сохранённого исследования

В корне полученного репозитория запустить **make reproduce**. Требования: CPython 3.12, Linux x86_64, glibc ≥ 2.27 и make; эталонная среда — Python 3.12.3 / Ubuntu 24.04. Зависимости исследования, презентации и шрифты включены в vendor. Команда проверяет INPUTS.sha256, пересчитывает все результаты, выполняет тесты и сверяет байты выходов с EXPECTED_RESULTS.sha256. Сеть и TeX не нужны.

Что проверить	Где находится
200 наблюдений, 11 колонок задания	results/preprints_ru.csv
ID и хеши отбора	results/sample.csv
Расширенные поля и источники	results/preprints.csv
Числа и этапы поиска	results/metrics.json; funnel.csv
Причины принятия и отказа	results/match_audit.json
Эталон и сверка с ним	data/review/gold.json; results/validation.json
Точность дат и хронология	results/quality.json; chronology.csv
Источники и словарь полей	docs/DATA_SOURCES.md; DATA_DICTIONARY.md

Новая выгрузка и смысл NA

make refresh запускает сетевой сбор в отдельный data/live/<UTC timestamp>/; API требуют доступной сети, страницы читаются через crawl4ai. Новый снимок требует отдельной проверки. Автономный пересчёт использует сохранённые ответы, а не текущее состояние внешних баз.

В таблице «нет» означает, что журнальная версия по принятому правилу не установлена. NA для журнала/DOI/даты у таких работ — неприменимость; NA для квартиля — неизвестный рейтинг; NA для точной задержки у опубликованной работы — неполная дата или обратная хронология. Эти причины различаются диагностическими полями расширенной таблицы. Пустой исход нельзя заменять нулём.