Путь статьи: от препринта до публикации

Мотивация

Во многих областях математики, информатики и физики статью сначала выкладывают на arXiv, и только потом она проходит рецензирование и выходит в журнале или сборнике конференции. Одни препринты публикуются быстро, другие через несколько лет, третьи не публикуются никогда.

Мы хотим предложить вам самим проследить путь препринтов: какая их доля доходит до публикации, сколько времени это занимает и куда их публикуют.

Хорошим итоговым результатом будет выборка из **200 препринтов**, сопоставленных с опубликованными версиями, и понятно описанная методика сопоставления.

> ✏️ **Политика использования ИИ**
>
> Использовать ИИ можно для работы с данными и API сайтов. Для анализа результатов и выбора критериев его лучше не использовать.

---

1. Какие препринты мы изучаем

- **Область.** Одна категория arXiv в математике, прикладной математике, информатике или физике. Например: *math.PR*, *math.CO*, *cs.LG*, *cs.DS*, *cond-mat.str-el*, *hep-th*.
- **Год.** Первая версия препринта выложена на arXiv в **2021 году**.
- **Размер.** Случайная выборка из **200 препринтов**, у которых выбранная категория основная (primary).

---

2. Что считается публикацией

Препринт считается опубликованным, если соответствующая статья вышла в рецензируемом журнале или сборнике конференции до даты, когда вы собирали данные.

Вы сами решаете и обосновываете:

- как сопоставлять препринт и статью, если у статьи изменилось название;
- какие даты сравнивать (например, первую версию на arXiv и онлайн-публикацию в журнале).

> **Вопрос, который вы решаете сами:** считать ли публикацией статью в сборнике конференции? Для информатики этот вопрос особенно важен.

---

3. Как действовать

1. Соберите выборку через **arXiv API** (https://info.arxiv.org/help/api).
2. Найдите опубликованные версии. Помогут поле *journal_ref* и DOI в метаданных arXiv, а также **OpenAlex API** (https://api.openalex.org). Для отдельных областей полезны специализированные базы: DBLP для информатики, zbMATH Open для математики, INSPIRE-HEP для физики высоких энергий.
3. Определите квартиль журналов по SJR 2025 через **SCImago** (https://www.scimagojr.com).
4. Проверьте вручную **10 препринтов**, которые вы сочли опубликованными, и **10**, которые вы сочли неопубликованными. Так вы увидите, насколько часто ошибается ваше сопоставление.

---

4. Что сдать

Таблицу (CSV или Google-таблицу) с колонками:

- название препринта;
- идентификатор arXiv;
- дата первой версии;
- опубликован ли препринт (да / нет);
- журнал или конференция;
- doi журнальной/конференционной версии;
- квартиль по SJR;
- дата публикации;
- задержка в днях;
- изменилось ли название (да / нет);
- уверенность в сопоставлении (высокая / средняя / низкая).

Короткий отчёт (1–2 страницы):

- **методика:** категория, как сопоставляли препринты со статьями, ответ на вопрос о конференциях;

- **контрольный набор:** 3 препринта, для которых вы вручную нашли опубликованную версию, и 2 препринта, которые трудно сопоставить автоматически, со ссылками. Хорошие трудные примеры: у статьи полностью сменилось название или препринт так и не был опубликован;
- **итоги ручной проверки:** сколько ошибок нашлось среди 20 проверенных препринтов;
- **5 спорных случаев** с объяснением решения.

Код, по которому можно воспроизвести выгрузку.

---

5. Устная беседа (7 минут)

Во время беседы расскажите:

1. **Методика.** Как вы находили опубликованные версии и почему именно так?
2. **Итог.** Какая доля препринтов опубликована, сколько в среднем занимает путь до публикации, какая доля выходит в журналах Q1?
3. **Проблемы.** Какие ошибки в данных и спорные случаи вам встретились? Что показала ручная проверка?
4. **Вывод.** Какие публикации ваша методика пропускает? Как на результат влияет то, что часть препринтов просто не успела выйти? Зачем нужны журналы, если препринт уже доступен всем?

---

6. Похожие исследования

- **Larivière V. et al. (2014).** *arXiv E-prints and the journal of record: An analysis of roles and relationships.* Journal of the Association for Information Science and Technology. Какая доля препринтов arXiv выходит в журналах и как это различается по областям.
- **Abdill R. J., Blekhman R. (2019).** *Tracking the popularity and outcomes of all bioRxiv preprints.* eLife. Сколько препринтов bioRxiv опубликовано, где и через сколько времени.
- **Klein M. et al. (2019).** *Comparing published scientific journal articles to their pre-print versions.* International Journal on Digital Libraries. Насколько тексты препринтов отличаются от опубликованных версий.